



## (12) 发明专利申请

(10) 申请公布号 CN 112560338 A

(43) 申请公布日 2021.03.26

(21) 申请号 202011435304.2

(22) 申请日 2020.12.10

(71) 申请人 东北大学

地址 110819 辽宁省沈阳市和平区文化路  
三巷11号

(72) 发明人 柴天佑 高懋婷

(74) 专利代理机构 广州三环专利商标代理有限公司 44202

代理人 晏静文 陈旭红

(51) Int.Cl.

G06F 30/27 (2020.01)

G06N 3/04 (2006.01)

G06N 3/08 (2006.01)

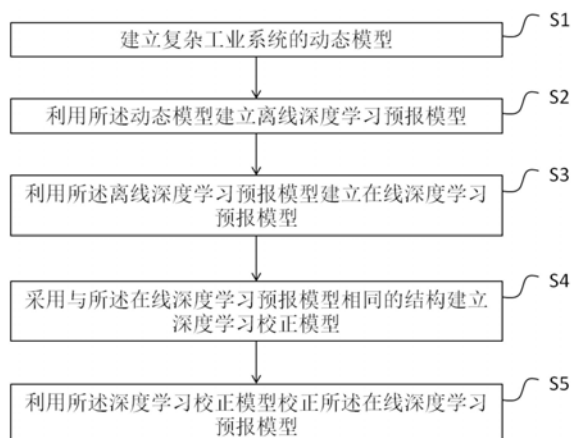
权利要求书3页 说明书12页 附图3页

### (54) 发明名称

基于自适应深度学习的复杂工业系统智能  
预报方法、装置、设备及存储介质

### (57) 摘要

本发明提供了一种基于自适应深度学习的复杂工业系统智能预报方法、装置、设备及存储介质。复杂工业系统智能预报方法包括：建立复杂工业系统的动态模型；利用所述动态模型建立离线深度学习预报模型；利用所述离线深度学习预报模型建立在线深度学习预报模型；采用与所述在线深度学习预报模型相同的结构建立深度学习校正模型；利用所述深度学习校正模型校正所述在线深度学习预报模型；其中，所述在线深度学习预报模型用于对所述复杂工业系统的参数进行实时预报。针对复杂工业系统预报精度较低及预报实时性差的问题，建立了包括离线深度学习预报模型、在线深度学习预报模型、深度学习校正模型及自校正的机制，实现了复杂工业系统的精确实时预报。



1. 一种基于自适应深度学习的复杂工业系统智能预报方法,其特征在于,所述方法包括:

建立复杂工业系统的动态模型;

利用所述动态模型建立离线深度学习预报模型;

利用所述离线深度学习预报模型建立在线深度学习预报模型;

采用与所述在线深度学习预报模型相同的结构建立深度学习校正模型;

利用所述深度学习校正模型校正所述在线深度学习预报模型;

其中,所述在线深度学习预报模型用于对所述复杂工业系统的参数进行实时预报。

2. 根据权利要求1所述的方法,其特征在于,所述建立复杂工业系统的动态模型,包括:确定所述动态模型的输入变量和输出变量,所述输出变量为被预报的变量;

所述利用所述动态模型建立离线深度学习预报模型,包括:采用LSTM建立所述离线深度学习预报模型,将所述动态模型的所述输入变量作为LSTM的输入,将所述动态模型的输出数据作为标签数据,采用离线训练算法,根据所述标签数据与所述离线深度学习预报模型输出之间的误差,确定LSTM的神经元个数、单元节点数、网络层数和各层的权值参数及偏置参数;

所述利用所述离线深度学习预报模型建立在线深度学习预报模型,包括:采用LSTM建立所述在线深度学习预报模型,所述在线深度学习预报模型的单个神经元的输入、神经元个数、单元节点数和网络层数均与所述离线深度学习预报模型相同,将所述离线深度学习预报模型的各层的权值参数和偏置参数作为所述在线深度学习预报模型的相应层的权值参数初始值和偏置参数初始值,采用在线训练算法,根据所述标签数据与所述在线深度学习预报模型输出之间的误差,在线校正所述在线深度学习预报模型的最后一层的权值参数和偏置参数;

所述采用与所述在线深度学习预报模型相同的结构建立深度学习校正模型,包括:采用LSTM建立所述深度学习校正模型,所述深度学习校正模型的单个神经元的输入、神经元个数、单元节点数和网络层数均与所述在线深度学习预报模型相同,通过训练算法,根据所述标签数据与所述深度学习校正模型输出之间的误差,实时校正所述深度学习校正模型各层的权值参数和偏置参数;

所述利用所述深度学习校正模型校正所述在线深度学习预报模型,包括:当满足预设条件时,采用所述深度学习校正模型的各层的权值参数和偏置参数替换所述在线深度学习预报模型的相应层的权值参数和偏置参数;

其中,所述深度学习校正模型输入的历史数据比所述在线深度学习预报模型输入的历史数据多。

3. 根据权利要求2所述的方法,其特征在于,所述在线校正所述在线深度学习预报模型的最后一层的权值参数和偏置参数,具体为在线校正所述在线深度学习预报模型的最后一层的部分权值参数和部分偏置参数。

4. 根据权利要求1-3任一所述的方法,其特征在于,所述复杂工业系统为氧化铝制取系统,所述在线深度学习预报模型用于对所述氧化铝制取系统的苛性碱浓度检测误差进行实时预报;所述苛性碱浓度检测误差为苛性碱浓度化验值与苛性碱浓度在线检测仪表的测量值之差。

5. 一种基于自适应深度学习的复杂工业系统智能预报装置, 其特征在于, 所述装置包括:

动态模型建模模块, 用于建立复杂工业系统的动态模型;

离线深度学习预报模型建模模块, 用于利用所述动态模型建立离线深度学习预报模型;

在线深度学习预报模型建模模块, 用于利用所述离线深度学习预报模型建立在线深度学习预报模型;

深度学习校正模型建模模块, 用于采用与所述在线深度学习预报模型相同的结构建立深度学习校正模型;

自校正模块, 用于利用所述深度学习校正模型校正所述在线深度学习预报模型;

其中, 所述在线深度学习预报模型用于对所述复杂工业系统的参数进行实时预报。

6. 根据权利要求5所述的装置, 其特征在于, 所述动态模型建模模块确定所述动态模型的输入变量和输出变量, 所述输出变量为被预报的变量;

所述离线深度学习预报模型建模模块采用LSTM建立所述离线深度学习预报模型, 将所述动态模型的所述输入变量作为LSTM的输入, 将所述动态模型的输出数据作为标签数据, 采用离线训练算法, 根据所述标签数据与所述离线深度学习预报模型输出之间的误差, 确定LSTM的神经元个数、单元节点数、网络层数和各层的权值参数及偏置参数;

所述在线深度学习预报模型建模模块采用LSTM建立所述在线深度学习预报模型, 所述在线深度学习预报模型的单个神经元的输入、神经元个数、单元节点数和网络层数均与所述离线深度学习预报模型相同, 将所述离线深度学习预报模型的各层的权值参数和偏置参数作为所述在线深度学习预报模型的相应层的权值参数初始值和偏置参数初始值, 采用在线训练算法, 根据所述标签数据与所述在线深度学习预报模型输出之间的误差, 在线校正所述在线深度学习预报模型的最后一层的权值参数和偏置参数;

所述深度学习校正模型建模模块采用LSTM建立所述深度学习校正模型, 所述深度学习校正模型的单个神经元的输入、神经元个数、单元节点数和网络层数均与所述在线深度学习预报模型相同, 通过训练算法, 根据所述标签数据与所述深度学习校正模型输出之间的误差, 实时校正所述深度学习校正模型的各层的权值参数和偏置参数;

所述自校正模块在满足预设条件时, 采用所述深度学习校正模型的各层的权值参数和偏置参数替换所述在线深度学习预报模型的相应层的权值参数和偏置参数;

其中, 所述深度学习校正模型输入的历史数据比所述在线深度学习预报模型输入的历史数据多。

7. 根据权利要求6所述的装置, 其特征在于, 所述在线校正所述在线深度学习预报模型的最后一层的权值参数和偏置参数, 具体为在线校正所述在线深度学习预报模型的最后一层的部分权值参数和部分偏置参数。

8. 根据权利要求5-7任一所述的装置, 其特征在于, 所述复杂工业系统为氧化铝制取系统, 所述在线深度学习预报模型用于对所述氧化铝制取系统的苛性碱浓度检测误差进行实时预报; 所述苛性碱浓度检测误差为苛性碱浓度化验值与苛性碱浓度在线检测仪表的测量值之差。

9. 一种用于实现权利要求1-4所述方法的基于自适应深度学习的复杂工业系统智能预

报设备,其特征在于,所述设备包括:端侧子设备、边缘侧子设备和云侧子设备;

所述端侧子设备用于采集所述复杂工业系统的输入数据和输出数据;

所述边缘侧子设备利用所述在线深度学习预报模型对所述复杂工业系统的参数进行实时预报;

所述云侧子设备用于训练所述深度学习校正模型,并实现所述深度学习校正模型对所述在线深度学习预报模型的校正。

10.一种计算机可读存储介质,其存储有计算机程序,其特征在于,所述程序被处理器执行时实现如权利要求1-4中任一所述的方法。

## 基于自适应深度学习的复杂工业系统智能预报方法、装置、设备及存储介质

### 技术领域

[0001] 本发明属于工业人工智能技术领域,涉及基于自适应深度学习的复杂工业系统智能预报方法、装置、设备及存储介质。

### 背景技术

[0002] 为了实现生产过程的闭环优化决策,需要对表征产品质量、效率、消耗的生产指标和关键工艺参数在线预报。由于工业过程的闭环优化决策的时间周期短,要求生产指标和关键工艺参数的预报模型在决策时间周期给出预报值。这就要求深度学习预报模型的训练数据集不能过大,训练算法不能耗时过长。加上生产制造过程的复杂性,造成生产指标和关键工艺参数与相关的生产过程输入与输出变量是复杂的动态系统。该动态系统往往具有强非线性,多变量强耦合,模型结构与输入与输出变量的阶次未知,甚至变化,生产原料等生产边界条件的变化、生产过程中的物质流、信息流、能源流的相互作用,使该动态系统的特性随生产时间而发生未知变化,导致该系统的输入、输出数据处于变化的、开放的、不确定的信息空间,使得已有的完备信息空间的深度学习技术无法应用于上述复杂的工业动态系统中建立该系统的预报模型。

### 发明内容

[0003] 本发明旨在至少在一定程度上解决相关技术中的技术问题之一。本发明的技术方案如下:

[0004] 一种基于自适应深度学习的复杂工业系统智能预报方法,包括如下步骤:

[0005] 建立复杂工业系统的动态模型;

[0006] 利用所述动态模型建立离线深度学习预报模型;

[0007] 利用所述离线深度学习预报模型建立在线深度学习预报模型;

[0008] 采用与所述在线深度学习预报模型相同的结构建立深度学习校正模型;

[0009] 利用所述深度学习校正模型校正所述在线深度学习预报模型;

[0010] 其中,所述在线深度学习预报模型用于对所述复杂工业系统的参数进行实时预报。

[0011] 进一步,作为优选,所述建立复杂工业系统的动态模型包括:确定所述动态模型的输入变量和输出变量,所述输出变量为被预报的变量;所述利用所述动态模型建立离线深度学习预报模型包括:采用LSTM建立所述离线深度学习预报模型,将所述动态模型的所述输入变量作为LSTM的输入,将所述动态模型的输出数据作为标签数据,采用离线训练算法,根据所述标签数据与所述离线深度学习预报模型输出之间的误差,确定LSTM的神经元个数、单元节点数、网络层数和各层的权值参数及偏置参数;所述利用所述离线深度学习预报模型建立在线深度学习预报模型包括:采用LSTM建立所述在线深度学习预报模型,所述在线深度学习预报模型的单个神经元的输入、神经元个数、单元节点数和网络层数均与所述

离线深度学习预报模型相同,将所述离线深度学习预报模型的各层的权值参数和偏置参数作为所述在线深度学习预报模型的相应层的权值参数初始值和偏置参数初始值,采用在线训练算法,根据所述标签数据与所述在线深度学习预报模型输出之间的误差,在线校正所述在线深度学习预报模型的最后一层的权值参数和偏置参数;所述采用与所述在线深度学习预报模型相同的结构建立深度学习校正模型包括:采用LSTM建立所述深度学习校正模型,所述深度学习校正模型的单个神经元的输入、神经元个数、单元节点数和网络层数均与所述在线深度学习预报模型相同,通过训练算法,根据所述标签数据与所述深度学习校正模型输出之间的误差,实时校正所述深度学习校正模型各层的权值参数和偏置参数;所述利用所述深度学习校正模型校正所述在线深度学习预报模型包括:当满足预设条件时,采用所述深度学习校正模型各层的权值参数和偏置参数替换所述在线深度学习预报模型的相应层的权值参数和偏置参数;其中,所述深度学习校正模型输入的历史数据比所述在线深度学习预报模型输入的历史数据多。

[0012] 进一步,作为优选,所述在线校正所述在线深度学习预报模型的最后一层的权值参数和偏置参数,具体为在线校正所述在线深度学习预报模型的最后一层的部分权值参数和部分偏置参数。

[0013] 进一步,作为优选,所述复杂工业系统为氧化铝制取系统,所述在线深度学习预报模型用于对所述氧化铝制取系统的苛性碱浓度检测误差进行实时预报;所述苛性碱浓度检测误差为苛性碱浓度化验值与苛性碱浓度在线检测仪表的测量值之差。

[0014] 一种基于自适应深度学习的复杂工业系统智能预报装置,包括:

[0015] 动态模型建模模块,用于建立复杂工业系统的动态模型;

[0016] 离线深度学习预报模型建模模块,用于利用所述动态模型建立离线深度学习预报模型;

[0017] 在线深度学习预报模型建模模块,用于利用所述离线深度学习预报模型建立在线深度学习预报模型;

[0018] 深度学习校正模型建模模块,用于采用与所述在线深度学习预报模型相同的结构建立深度学习校正模型;

[0019] 自校正模块,用于利用所述深度学习校正模型校正所述在线深度学习预报模型;

[0020] 其中,所述在线深度学习预报模型用于对所述复杂工业系统的参数进行实时预报。

[0021] 进一步,作为优选,所述动态模型建模模块确定所述动态模型的输入变量和输出变量,所述输出变量为被预报的变量;所述离线深度学习预报模型建模模块采用LSTM建立所述离线深度学习预报模型,将所述动态模型的所述输入变量作为LSTM的输入,将所述动态模型的输出数据作为标签数据,采用离线训练算法,根据所述标签数据与所述离线深度学习预报模型输出之间的误差,确定LSTM的神经元个数、单元节点数、网络层数和各层的权值参数及偏置参数;所述在线深度学习预报模型建模模块采用LSTM建立所述在线深度学习预报模型,所述在线深度学习预报模型的单个神经元的输入、神经元个数、单元节点数和网络层数均与所述离线深度学习预报模型相同,将所述离线深度学习预报模型各层的权值参数和偏置参数作为所述在线深度学习预报模型的相应层的权值参数初始值和偏置参数初始值,采用在线训练算法,根据所述标签数据与所述在线深度学习预报模型输出之间的

误差,在线校正所述在线深度学习预报模型的最后一层的权值参数和偏置参数;所述深度学习校正模型建模模块采用LSTM建立所述深度学习校正模型,所述深度学习校正模型的单个神经元的输入、神经元个数、单元节点数和网络层数均与所述在线深度学习预报模型相同,通过训练算法,根据所述标签数据与所述深度学习校正模型输出之间的误差,实时校正所述深度学习校正模型的各层的权值参数和偏置参数;所述自校正模块在满足预设条件时,采用所述深度学习校正模型的各层的权值参数和偏置参数替换所述在线深度学习预报模型的相应层的权值参数和偏置参数;其中,所述深度学习校正模型输入的历史数据比所述在线深度学习预报模型输入的历史数据多。

[0022] 进一步,作为优选,所述在线校正所述在线深度学习预报模型的最后一层的权值参数和偏置参数,具体为在线校正所述在线深度学习预报模型的最后一层的部分权值参数和部分偏置参数。

[0023] 进一步,作为优选,所述复杂工业系统为氧化铝制取系统,所述在线深度学习预报模型用于对所述氧化铝制取系统的苛性碱浓度检测误差进行实时预报;所述苛性碱浓度检测误差为苛性碱浓度化验值与苛性碱浓度在线检测仪表的测量值之差。

[0024] 一种用于实现上述智能预报方法的基于自适应深度学习的复杂工业系统智能预报设备,所述设备包括:端侧子设备、边缘侧子设备和云侧子设备;

[0025] 所述端侧子设备用于采集所述复杂工业系统的输入数据和输出数据;

[0026] 所述边缘侧子设备利用所述在线深度学习预报模型对所述复杂工业系统的参数进行实时预报;

[0027] 所述云侧子设备用于训练所述深度学习校正模型,并实现所述深度学习校正模型对所述在线深度学习预报模型的校正。

[0028] 一种计算机可读存储介质,其存储有计算机程序,所述程序被处理器执行时实现上述复杂工业系统智能预报方法。

[0029] 本发明针对复杂工业系统预报精度较低及预报实时性差的问题,建立了包括离线深度学习预报模型、在线深度学习预报模型、深度学习校正模型及自校正的机制,实现了复杂工业系统的精确实时预报。

## 附图说明

[0030] 图1为本发明实施例的复杂工业系统智能预报方法实现流程图;

[0031] 图2为本发明一个实施例的苛性碱浓度检测误差智能预报方法实现流程图;

[0032] 图3为输入数据时间序列窗口长度取不同值时在线深度学习预报模型的预报误差;

[0033] 图4为本发明一个实施例的复杂工业系统智能预报装置的结构示意图;

[0034] 图5为本发明一个实施例的复杂工业系统智能预报设备的结构示意图。

## 具体实施方式

[0035] 下面将结合本发明实施例中的附图,对本发明实施例中的技术方案进行清楚、完整地描述,显然,所描述的实施例仅仅是本发明一部分实施例,而不是全部的实施例。基于本发明中的实施例,本领域普通技术人员在没有作出创造性劳动前提下所获得的所有其他

实施例,都属于本发明保护的范围。

[0036] 图1为本发明实施例的复杂工业系统智能预报方法实现流程图,该方法包括以下步骤:

[0037] S1:建立复杂工业系统的动态模型。

[0038] 具体的,通过工业过程的机理分析,以需要预报的生产指标或关键工艺参数为工业系统动态模型的输出变量,影响该输出变量的工业过程的输入和输出为该动态模型的输入变量,并将该动态模型的输出历史数据以及预报误差历史数据作为该动态模型的输入变量,采用未知常数 $n$ 表示该动态系统的输入与输出变量的未知变化的阶次。采用下式表示该工业系统的动态模型:

$$[0039] \quad s(k) = f(s(k-1), \dots, s(k-n), y_i(k), \dots, y_i(k-n+1), u_i(k), \dots, u_i(k-n+1), \Delta s(k-1), \dots, \Delta s(k-n)) \quad (1)$$

[0040] 其中, $f$ 是未知变化的非线性函数; $s(k)$ 为该动态模型 $k$ 时刻的输出; $y_i(k)$ 为工业过程 $k$ 时刻的第 $i$ 个输出, $u_i(k)$ 为工业过程 $k$ 时刻的第 $i$ 个输入, $i=1, \dots, m$ ; $\Delta s(k-1) = s(k-1) - \hat{s}(k-1)$ 为 $k-1$ 时刻的预报误差,即 $k-1$ 时刻该动态模型的输出 $s(k-1)$ 与预报模型的输出 $\hat{s}(k-1)$ 之差。

[0041] S2:利用所述动态模型建立离线深度学习预报模型。

[0042] 具体的,采用LSTM建立所述离线深度学习预报模型,将所述动态模型的所述输入变量作为LSTM的输入,将所述动态模型的输出数据作为标签数据,采用离线训练算法,根据所述标签数据与所述离线深度学习预报模型输出之间的误差,确定LSTM的神经元个数、单元节点数、网络层数和各层的权值参数及偏置参数。

[0043] 步骤S2包括步骤S21和S22。

[0044] 步骤S21为:采用LSTM结构建立离线深度学习预报模型,将LSTM的初始网络层数设置为1,通过训练算法,根据标签数据与离线深度学习预报模型输出之差确定所述LSTM的神经元个数和单元节点数。

[0045] 具体的,选择(1)式中的输入变量作为第 $j$ 个单个神经元的输入 $x_j(k+j-n)$  ( $j=1, \dots, n$ ),阶次 $n$ 为神经元的个数,即:

$$[0046] \quad x_j(k+j-n) = [s(k+j-n-1), y_i(k+j-n), u_i(k+j-n), \Delta s(k+j-n-1)]^T \quad (2)$$

[0047] 其中, $j=1, \dots, n$ ;  $i=1, \dots, m$ 。

[0048] 以工业系统动态模型(1)的输出数据 $s(k)$ 作为标签数据,采用(1)式的输入、输出数据组成大数据样本,采用离线训练算法,使标签数据与离线深度学习预报模型输出之差尽可能小,确定LSTM的神经元个数 $n$ 、单元节点数 $\bar{n}$ 。

[0049] 步骤S22为:固定所述LSTM的神经元个数和单元节点数,改变所述LSTM的网络层数,根据不同网络层数对应的所述标签数据与所述离线深度学习预报模型输出之差,选择LSTM的网络层数。

[0050] 具体的,固定所述LSTM的单个神经元个数 $n$ 和LSTM单元节点数 $\bar{n}$ ,通过增加LSTM的网络层数来减小离线深度学习预报模型的输出与标签数据的误差,使该误差尽可能小,确定LSTM的网络层数以及各层权值参数和偏置参数。

[0051] S3:利用所述离线深度学习预报模型建立在线深度学习预报模型。



[0052] 具体的,采用LSTM建立所述在线深度学习预报模型,所述在线深度学习预报模型的单个神经元的输入、神经元个数、单元节点数和网络层数均与所述离线深度学习预报模型相同,将所述离线深度学习预报模型的各层的权值参数和偏置参数作为所述在线深度学习预报模型的相应层的权值参数初始值和偏置参数初始值,采用固定数据量的时间序列N来在线校正该在线深度学习预报模型最后一层的权值参数和偏置参数,来保证在线深度学习预报模型在确定的优化决策时间周期内完成预报算法。采用训练算法,通过使预报误差尽可能小,确定N。采用时间序列长度为N的数据集,采用递推算法,即k时刻在线深度学习预报模型的输入数据的时刻序列为 $(k-N+1), \dots, k$ ;  $(k+1)$ 时刻在线深度学习预报模型的输入数据的时刻序列为 $(k-N+2), \dots, (k+1)$ 。在线深度学习预报模型用于对复杂工业系统的参数进行实时预报。

[0053] S4:采用与所述在线深度学习预报模型相同的结构建立深度学习校正模型。

[0054] 具体的,采用LSTM建立所述深度学习校正模型,所述深度学习校正模型的单个神经元的输入、神经元个数、单元节点数和网络层数均与所述在线深度学习预报模型相同,采用当前时刻以及以前所有时刻的模型(1)式的输入数据作为深度学习校正模型的输入数据,训练深度学习校正模型的各层的所有权值参数和偏置参数,获得深度学习校正模型的预报值 $\tilde{s}(k)$ 和预报误差 $\Delta\tilde{s}(k) = s(k) - \tilde{s}(k)$ 。

[0055] S5:利用所述深度学习校正模型校正所述在线深度学习预报模型。

[0056] 具体的,利用所述深度学习校正模型自适应校正所述在线深度学习预报模型,设定预报误差的区间上界为 $\delta$ ,当在线深度学习预报模型的预报误差 $|\Delta s(k)| \geq \delta$ ,且深度学习校正模型的预报误差 $|\Delta\tilde{s}(k)| < \delta$ ,采用深度学习校正模型的各层的权值参数和偏置参数替换在线深度学习预报模型的相应层的权值参数和偏置参数,保证在线深度学习预报模型的预报误差在设定预报误差的区间内,即 $|\Delta s(k)| < \delta$ 。

[0057] 进一步的,在一个实施例中,复杂工业系统智能预报方法可用于氧化铝制取系统的苛性碱浓度检测误差的预报。

[0058] 氧化铝具有硬度高、熔点高等优良特性,常用于冶炼金属铝和制造耐火材料,是军工、航天和国民经济中具有支撑作用的战略资源。目前,制取氧化铝的主要方法是拜耳法,其基本工艺流程通常是将碎铝土矿按配比要求加入石灰和苛性碱溶液进行磨制,再利用苛性碱溶液在一定温度、一定压力条件下溶出铝土矿制得铝酸钠溶液,铝酸钠溶液净化后经过降温、添加晶种、搅拌解析析出氢氧化铝晶体,析出的氢氧化铝经分离、洗涤、焙烧后得到氧化铝。分离氢氧化铝后的母液(主要成分是苛性碱)经蒸发过程后再重新溶出新的铝土矿,进入下一循环。

[0059] 氧化铝溶液的苛性碱浓度是氧化铝蒸发过程的关键工艺指标,关系到氧化铝的最终产品质量。日常苛性碱浓度检测是依靠人工按固定周期取样后再化验的手段获得准确的苛性碱浓度值,然而由于取样间隔和化验所需时间较长,苛性碱浓度的检测存在严重滞后性,无法实现蒸发过程的运行优化控制。

[0060] 为了实现蒸发过程的运行优化控制,一些氧化铝企业以昂贵的价格引进苛性碱浓度在线测量装置。实际生产中,铝土矿品位的变化和生产过程运行的变化导致该检测装置测得的苛性碱浓度与化验结果差距大,无法使用。由于该误差的动态特性具有未知强非线性

性,模型阶次未知,生产原料等生产边界条件时常波动、各工艺流程和物料间相互作用,因此该误差动态系统的特性随生产时间而发生未知变化,导致该系统的输入、输出数据处于变化的、开放的、不确定的信息空间,使得已有的完备信息空间的深度学习技术难以应用于氧化铝蒸发过程苛性碱浓度误差预报动态系统中。除此之外,由于氧化铝制取工业过程的运行优化决策的时间周期短,要求生产指标和关键工艺参数的预报模型在决策时间周期给出预报值。这就要求深度学习预报模型的训练数据集不能过大,训练算法不能耗时过长。

[0061] 本发明实施例针对氧化铝制取系统预报精度较低及预报实时性差的问题,建立了包括离线深度学习预报模型、在线深度学习预报模型、深度学习校正模型及自校正的机制,实现了氧化铝制取系统的精确实时预报。

[0062] 图2为本发明一个实施例的苛性碱浓度检测误差智能预报方法实现流程图,该方法包括以下步骤:

[0063] S1':建立苛性碱浓度化验值与苛性碱浓度在线检测仪表的测量值的检测误差动态模型。

[0064] 具体的,由于苛性碱浓度在线检测仪表以氧化铝溶液折光度和温度为输入,通过模型产生浓度测量值,因此该检测误差动态模型的输入包括氧化铝溶液的折光度和温度,并将苛性碱浓度化验值和苛性碱浓度检测仪表测量值之差的历史值作为该检测误差动态模型的输入,采用未知常数 $n$ 表示该动态系统的输入与输出变量的未知阶次,建立苛性碱浓度检测误差动态模型如下:

$$[0065] \quad \Delta r(k) = \hat{f}(y_1(k), \dots, y_1(k-n+1), y_2(k), \dots, y_2(k-n+1), \Delta r(k-1), \dots, \Delta r(k-n)) \quad (3)$$

[0066] 其中,  $\hat{f}$  是未知变化的非线性函数;  $y_1(k)$  为 $k$ 时刻的氧化铝溶液折光度;  $y_2(k)$  为 $k$ 时刻的氧化铝溶液温度;  $\Delta r(k) = r(k) - \bar{r}(k)$ , 为 $k$ 时刻苛性碱浓度化验值 $r(k)$ 与苛性碱浓度检测仪表测量值 $\bar{r}(k)$ 之差。

[0067] S2':利用所述检测误差动态模型建立离线深度学习预报模型。

[0068] 具体的,采用LSTM建立所述离线深度学习预报模型,将所述检测误差动态模型的所述输入变量作为LSTM的输入,将所述检测误差动态模型的输出数据作为标签数据,采用离线训练算法,根据所述标签数据与所述离线深度学习预报模型输出之间的误差,确定LSTM的神经元个数、单元节点数、网络层数和各层的权值参数及偏置参数。

[0069] 步骤S2'包括步骤S21'和S22'。

[0070] 步骤S21'为:采用LSTM结构建立离线深度学习预报模型,将LSTM的初始网络层数设置为1,通过训练算法,根据标签数据与离线深度学习预报模型输出之差确定所述LSTM的神经元个数和单元节点数。

[0071] 具体的,选择(3)式中第 $j$ 个输入变量作为第 $j$ 个单个神经元的输入 $x_j(k+j-n)$  ( $j=1, \dots, n$ ),即:

$$[0072] \quad x_j(k+j-n) = [y_1(k+j-n), y_2(k+j-n), \Delta r(k+j-n-1)]^T \quad (4)$$

[0073] 其中,  $j=1, \dots, n$ ;  $n$ 为神经元的个数。

[0074] 采用如下训练算法确定LSTM的神经元个数 $n$ 、单元节点数 $\bar{n}$ :

[0075] 选择层数为1的LSTM神经网络,利用(3)式所示输入输出变量所构成的大数据样本,以苛性碱浓度化验值与检测仪表测量值的误差值 $\Delta r(k)$ 作为标签数据,采用训练算法,

使k时刻的标签数据  $\Delta r(k)$  与k时刻的离线深度学习预报模型输出  $\Delta \hat{r}_0(k)$  的误差尽可能小来确定n和  $\bar{h}$ 。

[0076] 训练算法的目标函数为：

$$[0077] \quad \mathcal{L}_{MAE}(\Delta \hat{r}_0, \Delta r) = \frac{\sum_{k=1}^M \|\Delta r(k) - \Delta \hat{r}_0(k)\|_1}{M} \quad (5)$$

[0078] 其中,M表示训练数据的数据量。

[0079] 标签数据  $\Delta r(k)$ ：

$$[0080] \quad \Delta r(k) = r(k) - \bar{r}(k) \quad (6)$$

[0081] 离线深度学习预报模型的预报值  $\Delta \hat{r}_0(k)$  是第n个神经元输出h(k)的加权表达式：

$$[0082] \quad \Delta \hat{r}_0(k) = W_d \times h(k) + b_d \quad (7)$$

[0083] 其中,h(k)为  $\bar{h} \times 1$  向量,  $W_d$  表示权值参数,  $W_d$  为  $1 \times \bar{h}$  向量,  $b_d$  表示偏置参数。

$$[0084] \quad h(k) = o_k * \tanh(C(k)) \quad (8)$$

[0085] 其中,  $o_k$  为输出门的输入,  $o_k$  为  $\bar{h} \times 1$  向量

$$[0086] \quad o_k = \sigma(W_o \cdot [h(k-1), x_j(k)]^T + b_o) \quad (9)$$

[0087] 其中h(k-1)是第(n-1)个神经元的输出,  $[h(k-1), x_j(k)]^T$  为  $(\bar{h}+3) \times 1$  向量,  $W_o$  和  $b_o$  为神经网络第一层的连接权和偏置,  $W_o$  为  $\bar{h} \times (\bar{h}+3)$  矩阵,  $b_o$  为  $\bar{h} \times 1$  向量。 $\sigma$  为sigmoid函数,  $\sigma(z) = (1 + e^{-z})^{-1}$ , z 为向量  $[W_o \cdot [h(k-1), x_j(k)]^T + b_o]$  的元素。

[0088]  $C(k)$  为长期记忆状态,  $C(k)$  为  $\bar{h} \times 1$  向量,  $\tanh(\cdot)$  为双曲线正切函数,

$$\tanh(c_i(k)) = \frac{\sinh(c_i(k))}{\cosh(c_i(k))}, c_i(k) \text{ 是向量 } C(k) \text{ 的第 } i \text{ 个元素, } i \in [1, \dots, \bar{h}].$$

$$[0089] \quad C(k) = f_k * C(k-1) + i_k * \tilde{C}_k \quad (10)$$

[0090] 其中,  $f_k$ 、 $i_k$  和  $\tilde{C}_k$  为  $\bar{h} \times 1$  的向量, 由下式计算

$$f_k = \sigma(W_f \cdot [h(k-1), x_j(k)]^T + b_f)$$

$$[0091] \quad i_k = \sigma(W_i \cdot [h(k-1), x_j(k)]^T + b_i) \quad (11)$$

$$\tilde{C}_k = \tanh(W_C \cdot [h(k-1), x_j(k)]^T + b_C)$$

[0092] 其中,  $W_f$ ,  $W_i$ ,  $W_C$  为LSTM单元连接权值, 均为  $\bar{h} \times (\bar{h}+3)$  矩阵,  $b_f$ ,  $b_i$ ,  $b_C$  为LSTM单元偏置, 均为  $\bar{h} \times 1$  向量。

[0093] 取  $n=1, 2 \dots 22$ ,  $\bar{h}=1, 2 \dots 205$ , 使用(5) — (11) 式采用梯度下降算法使(5)式极小, 实验过程中当神经元的个数n为20且LSTM的单元节点数  $\bar{h}$  为180时测试误差最小, 因此确定神经元的个数n为20, LSTM的单元节点数  $\bar{h}$  为180。

[0094] 步骤S22' 为: 将离线深度学习预报模型的神经元个数n固定为20, 同时将单元节点数  $\bar{h}$  固定为180, 通过增加网络层数使离线深度学习预报模型输出  $\Delta \hat{r}_0(k)$  和标签数据  $\Delta r(k)$

之间的误差尽可能小来确定层数L。

[0095] 训练算法的目标函数如式(5), 标签数据的表达式如式(6)。离线深度学习预报模型的预报值 $\Delta\hat{r}_0(k)$ 是第L层LSTM的第20个神经元输出 $h^L(k)$ 的加权表达式:

$$[0096] \quad \Delta\hat{r}_0(k) = W_d^L \times h^L(k) + b_d^L \quad (12)$$

[0097] 其中,  $h^L(k)$  为 $180 \times 1$ 向量,  $W_d^L$  表示权值参数,  $W_d^L$  为 $1 \times 180$ 向量,  $b_d^L$  表示偏置参数。

$$[0098] \quad h^L(k) = o_k^L * \tanh(C^L(k)) \quad (13)$$

[0099] 其中,  $o_k^L$  为输出门的输入,  $o_k^L$  为 $180 \times 1$ 向量

$$[0100] \quad o_k^L = \sigma(W_o^L \cdot [h^L(k-1), h^{L-1}(k)]^T + b_o^L) \quad (14)$$

[0101] 其中,  $h^L(k-1)$  为第L层LSTM神经网络的第19个神经元的输出,  $h^{L-1}(k)$  为第L-1层LSTM神经网络的第20个神经元的输出, 也是第L层LSTM的第20个神经元的输入。

[0102]  $C^L(k)$  为长期记忆状态,  $C^L(k)$  为 $180 \times 1$ 向量

$$[0103] \quad C^L(k) = f_k^L * C^L(k-1) + i_k^L * \tilde{C}_k^L \quad (15)$$

[0104] 其中,  $f_k^L$ 、 $i_k^L$  和  $\tilde{C}_k^L$  为 $180 \times 1$ 的向量, 由下式计算

$$[0105] \quad \begin{aligned} f_k^L &= \sigma(W_f^L \cdot [h^L(k-1), h^{L-1}(k)]^T + b_f^L) \\ i_k^L &= \sigma(W_i^L \cdot [h^L(k-1), h^{L-1}(k)]^T + b_i^L) \\ \tilde{C}_k^L &= \tanh(W_C^L \cdot [h^L(k-1), h^{L-1}(k)]^T + b_C^L) \end{aligned} \quad (16)$$

[0106] 其中, LSTM单元连接权值  $W_f^L$ 、 $W_i^L$ 、 $W_C^L$  和  $W_o^L$  为 $180 \times 360$ 矩阵, LSTM单元偏置  $b_f^L$ 、 $b_i^L$ 、 $b_C^L$  和  $b_o^L$  为 $180 \times 1$ 向量。

[0107] 取 $L=1, 2, 3, 4$ , 使用(5)、(6)和(12) — (16)式采用梯度下降算法使(5)式极小, 实验结果如表1所示, 当LSTM神经网络的层数L为2时预报精度最高且训练时间较短, 因此确定神经网络层数为两层, 同时确定离线深度学习预报模型各层的连接权参数和偏置参数。

[0108] 表1测试误差与神经网络中LSTM单元层数

	LSTM 单元层数	1	2	3	4
[0109]	RMSE	1.942	1.81	1.841	1.955
	MAE	0.641	0.5573	0.587	0.770
	MAPE	0.275	0.239	0.251	0.329
	迭代周期	<0.5 秒	1 秒	43 秒	111 秒

[0110] S3': 利用所述离线深度学习预报模型建立在线深度学习预报模型。

[0111] 具体的, 采用LSTM建立所述在线深度学习预报模型, 所述在线深度学习预报模型的单个神经元的输入、神经元个数、单元节点数和网络层数均与所述离线深度学习预报模型相同, 将所述离线深度学习预报模型各层的权值参数和偏置参数作为所述在线深度学习预报模型的相应层的权值参数初始值和偏置参数初始值, 并在线校正在线深度学习预报模型的第二层的连接权 $W_d^2$ 和偏置 $b_d^2$ 。

[0112] 在线深度学习预报模型如下：

$$[0113] \quad \Delta \hat{r}_1(k) = W_d^2(k) \times h^2(k) + b_d^2(k) \quad (17)$$

[0114] 式中,  $W_d^2(k)$  为  $W_d^2$  的  $k$  时刻的校正值,  $W_d^2(k) \in \mathbb{R}^{1 \times 80}$ ,  $b_d^2(k)$  为  $b_d^2$  的  $k$  时刻的校正值,  $h^2(k)$  为第2层LSTM单元最后一个神经元输出。为了确保在规定的预报周期内在线完成预报算法,通过遍历确定在线深度学习预报模型的输入数据时间序列窗口长度  $N$ 。

[0115] 目标函数为：

$$[0116] \quad \mathcal{L}_{MAE}^N(\Delta \hat{r}_1, \Delta r) = \frac{\sum_{k=N+1}^k \|\Delta r(k) - \Delta \hat{r}_1(k)\|_1}{N} \quad (18)$$

[0117]  $W_d^2$  和  $b_d^2$  的校正算法为：

$$[0118] \quad W_d^2 := W_d^2 + \eta \frac{\partial(\mathcal{L}_{MAE}^N(\Delta \hat{r}_1, \Delta r))}{\partial W_d^2} \quad (19)$$

$$[0119] \quad b_d^2 := b_d^2 + \eta \frac{\partial(\mathcal{L}_{MAE}^N(\Delta \hat{r}_1, \Delta r))}{\partial(b_d^2)} \quad (20)$$

[0120] 取  $N=500, \dots, 900$ , 采用上述算法校正  $W_d^2$  和  $b_d^2$ , 由 (17) 和 (18) 式计算预报误差实验结果如图3所示。当  $N$  小于820时无法满足预报模型的精度需求, 当  $N$  大于820时会产生冗余、增加网络计算量, 当  $N$  为820时预报误差最小, 因此确定在线深度学习预报模型输入数据序列的时间长度  $N=820$ 。

[0121] 相应的,  $(k+1)$  时刻的苛性碱浓度检测误差的在线深度学习预报模型为：

$$[0122] \quad \Delta \hat{r}_1(k+1) = W_d^2(k+1) \times h^2(k+1) + b_d^2(k+1) \quad (21)$$

[0123]  $(k+1)$  时刻在线深度学习预报模型利用  $N$  为820的时间序列  $(k-818), (k-817), \dots, (k+1)$  时刻的输入数据, 采用如下算法校正权值参数  $W_d^2(k+1)$  和偏置参数  $b_d^2(k+1)$ , 由 (21) 式求取  $(k+1)$  时刻苛性碱浓度检测误差预报值  $\Delta \hat{r}_1(k+1)$ ：

$$[0124] \quad W_d^2(k+1) = W_d^2(k) + \eta \frac{\partial(\mathcal{L}_{MAE}^N(\Delta \hat{r}_1, \Delta r))}{\partial W_d^2(k)} \quad (22)$$

$$[0125] \quad b_d^2(k+1) = b_d^2(k) + \eta \frac{\partial(\mathcal{L}_{MAE}^N(\Delta \hat{r}_1, \Delta r))}{\partial(b_d^2(k))} \quad (23)$$

[0126] 其中  $\eta$  表示在线深度学习预报模型中参数校正的学习率,  $\eta=0.0005$ 。

[0127] S4' : 采用与所述在线深度学习预报模型相同的结构建立深度学习校正模型。

[0128] 具体的, 采用LSTM建立所述深度学习校正模型, 所述深度学习校正模型的单个神经元的输入、神经元个数、单元节点数和网络层数均与所述在线深度学习预报模型相同。采用当前  $k$  时刻以及以前所有时刻即  $k, \dots, 2, 1$  的模型 (3) 式的所有输入数据作为深度学习校正模型的输入数据, 采用下列目标函数和训练算法校正该深度学习校正模型的第一层和第二层的所有权值参数和偏置参数。

[0129] 目标函数为：

$$[0130] \quad \mathcal{L}_{MAE}^k(\Delta\tilde{r}, \Delta r) = \frac{\sum_{t=1}^k \|\Delta r(t) - \Delta\tilde{r}(t)\|_1}{k} \quad (24)$$

[0131] 其中,  $k$  为当前时刻,  $\Delta\tilde{r}(t)$  为  $t$  时刻深度学习校正模型的输出。

[0132]  $W_d^2$ 、 $b_d^2$ 、 $W_o^2$ 、 $b_o^2$  的校正算法如下。

$$[0133] \quad W_d^2(k+1) = W_d^2(k) + \eta \frac{\partial(\mathcal{L}_{MAE}^k(\Delta\tilde{r}, \Delta r))}{\partial W_d^2(k)} \quad (25)$$

$$[0134] \quad b_d^2(k+1) = b_d^2(k) + \eta \frac{\partial(\mathcal{L}_{MAE}^k(\Delta\tilde{r}, \Delta r))}{\partial(b_d^2(k))} \quad (26)$$

$$[0135] \quad W_o^2(k+1) = W_o^2(k) + \eta \frac{\partial(\mathcal{L}_{MAE}^k(\Delta\tilde{r}, \Delta r))}{\partial W_o^2(k)} \quad (27)$$

$$[0136] \quad b_o^2(k+1) = b_o^2(k) + \eta \frac{\partial(\mathcal{L}_{MAE}^k(\Delta\tilde{r}, \Delta r))}{\partial(b_o^2(k))} \quad (28)$$

[0137] 其中,  $\eta$  表示校正模型中参数校正的学习率,  $\eta = 0.0005$ 。采用上述校正算法可校正该深度学习校正模型的第一层和第二层其余连接权参数  $W_f, W_i, W_c, W_o, W_d, W_f^2, W_i^2, W_c^2$  和偏置参数  $b_f, b_i, b_c, b_o, b_d, b_f^2, b_i^2, b_c^2$ 。

[0138] S5': 利用所述深度学习校正模型校正在线深度学习预报模型。

[0139] 具体的, 利用所述深度学习校正模型自适应校正所述在线深度学习预报模型, 设定预报误差的区间上界为  $\delta$ ,  $\delta = 1.5g/l$ , 采样时刻  $i$  的区间为  $[k, k-1, \dots, k-99]$ 。连续100个最新时刻的采样点内, 当在线深度学习预报模型中预报误差  $|\Delta r(i) - \Delta \hat{r}_1(i)|$  未超过区间上界的采样点个数小于99而深度学习校正模型中存在99个采样点的预报误差  $|\Delta r(i) - \Delta \tilde{r}_1(i)|$  未超区间上界时, 采用深度学习校正模型各层权值参数和偏置参数校正在线深度学习预报模型各层权值参数和偏置参数, 保证在线深度学习预报模型的预报误差在设定预报误差的区间范围内。

[0140] 将本发明实施例的苛性碱浓度检测误差预报方法应用在山西某氧化铝厂蒸发过程中的效果如表2所示。

[0141] 表2中的仪表测量值为苛性碱浓度仪表在线测量值, 补偿后的仪表值为苛性碱浓度仪表在线测量值与苛性碱浓度检测误差在线深度学习预报模型输出的预报值之和。表2分别统计了仪表测量值、补偿后的仪表值与苛性碱浓度化验值的均方根误差RMSE以及在生产工艺规定的误差区间范围内的合格率。由表2可以看出, 采用本发明实施例的苛性碱浓度检测误差预报方法对仪表测量值进行补偿后, 可将苛性碱浓度仪表测量值与化验值之间的RMSE由11.25下降为0.50, 合格率由10.75%提升为99.62%, 为实现氧化铝蒸发过程的闭环运行优化控制创造了条件。

[0142] 表2苛性碱浓度在线深度学习预报模型应用效果

	相关配置	均方根误差 <i>RMSE</i>	合格率 <i>P</i>
[0143]	仪表测量值	11.25	10.75%
	补偿后的仪表值	0.50	99.62 %

[0144] 在一个实施例中,如图4所示,提供了一种基于自适应深度学习的复杂工业系统智能预报装置,包括:动态模型建模模块、离线深度学习预报模型建模模块、在线深度学习预报模型建模模块、深度学习校正模型建模模块和自校正模块,其中:

[0145] 动态模型建模模块用于建立复杂工业系统的动态模型;

[0146] 离线深度学习预报模型建模模块用于利用所述动态模型建立离线深度学习预报模型;

[0147] 在线深度学习预报模型建模模块用于利用所述离线深度学习预报模型建立在线深度学习预报模型;

[0148] 深度学习校正模型建模模块用于采用与所述在线深度学习预报模型相同的结构建立深度学习校正模型;

[0149] 自校正模块用于利用所述深度学习校正模型校正所述在线深度学习预报模型;

[0150] 其中,所述在线深度学习预报模型用于对所述复杂工业系统的参数进行实时预报。

[0151] 在其中一个实施例中,所述动态模型建模模块确定所述动态模型的输入变量和输出变量,所述输出变量为被预报的变量;所述离线深度学习预报模型建模模块采用LSTM建立所述离线深度学习预报模型,将所述动态模型的所述输入变量作为LSTM的输入,将所述动态模型的输出数据作为标签数据,采用离线训练算法,根据所述标签数据与所述离线深度学习预报模型输出之间的误差,确定LSTM的神经元个数、单元节点数、网络层数和各层的权值参数及偏置参数;所述在线深度学习预报模型建模模块采用LSTM建立所述在线深度学习预报模型,所述在线深度学习预报模型的单个神经元的输入、神经元个数、单元节点数和网络层数均与所述离线深度学习预报模型相同,将所述离线深度学习预报模型的各层的权值参数和偏置参数作为所述在线深度学习预报模型的相应层的权值参数初始值和偏置参数初始值,采用在线训练算法,根据所述标签数据与所述在线深度学习预报模型输出之间的误差,在线校正所述在线深度学习预报模型的最后一层的权值参数和偏置参数;所述深度学习校正模型建模模块采用LSTM建立所述深度学习校正模型,所述深度学习校正模型的单个神经元的输入、神经元个数、单元节点数和网络层数均与所述在线深度学习预报模型相同,通过训练算法,根据所述标签数据与所述深度学习校正模型输出之间的误差,实时校正所述深度学习校正模型的各层的权值参数和偏置参数;所述自校正模块在满足预设条件时,采用所述深度学习校正模型的各层的权值参数和偏置参数替换所述在线深度学习预报模型的相应层的权值参数和偏置参数;其中,所述深度学习校正模型输入的历史数据比所述在线深度学习预报模型输入的历史数据多。

[0152] 在其中一个实施例中,所述在线校正所述在线深度学习预报模型的最后一层的权值参数和偏置参数,具体为在线校正所述在线深度学习预报模型的最后一层的部分权值参

数和部分偏置参数。

[0153] 在其中一个实施例中,所述复杂工业系统为氧化铝制取系统,所述在线深度学习预报模型用于对所述氧化铝制取系统的苛性碱浓度检测误差进行实时预报;所述苛性碱浓度检测误差为苛性碱浓度化验值与苛性碱浓度在线检测仪表的测量值之差。

[0154] 关于复杂工业系统智能预报装置的具体限定可以参见上文中对于复杂工业系统智能预报方法的限定,在此不再赘述。上述复杂工业系统智能预报装置中的各个模块可全部或部分通过软件、硬件及其组合来实现。上述各模块可以以硬件形式内嵌于或独立于计算机设备中的处理器中,也可以以软件形式存储于计算机设备的存储器中,以便于处理器调用执行以上各个模块对应的操作。

[0155] 在一个实施例中,如图5所示,提供了一种用于实现上述各实施例中的智能预报方法的基于自适应深度学习的复杂工业系统智能预报设备,包括:端侧子设备、边缘侧子设备和云侧子设备;所述端侧子设备用于采集所述复杂工业系统的输入数据和输出数据;所述边缘侧子设备利用所述在线深度学习预报模型对所述复杂工业系统的参数进行实时预报;所述云侧子设备用于训练所述深度学习校正模型,并实现所述深度学习校正模型对所述在线深度学习预报模型的校正。

[0156] 在一个实施例中,提供了一种计算机可读存储介质,其存储有计算机程序,所述程序被处理器执行时实现上述各实施例中的复杂工业系统智能预报方法。

[0157] 在不相互矛盾的情况下,本领域的技术人员可以将本说明书中描述的不同实施例以及不同实施例的特征进行结合和组合。

[0158] 综上所述,本发明实施例提出的复杂工业系统智能预报方法、装置和设备针对复杂工业系统预报精度较低及预报实时性差的问题,建立了包括离线深度学习预报模型、在线深度学习预报模型、深度学习校正模型及自校正的机制,实现了复杂工业系统的精确实时预报。

[0159] 以上所述,仅为本发明的具体实施方式,但本发明的保护范围并不局限于此,任何熟悉本技术领域的技术人员在本发明揭露的技术范围内,可轻易想到其各种变化或替换,这些都应涵盖在本发明的保护范围之内。因此,本发明的保护范围应以所述权利要求的保护范围为准。



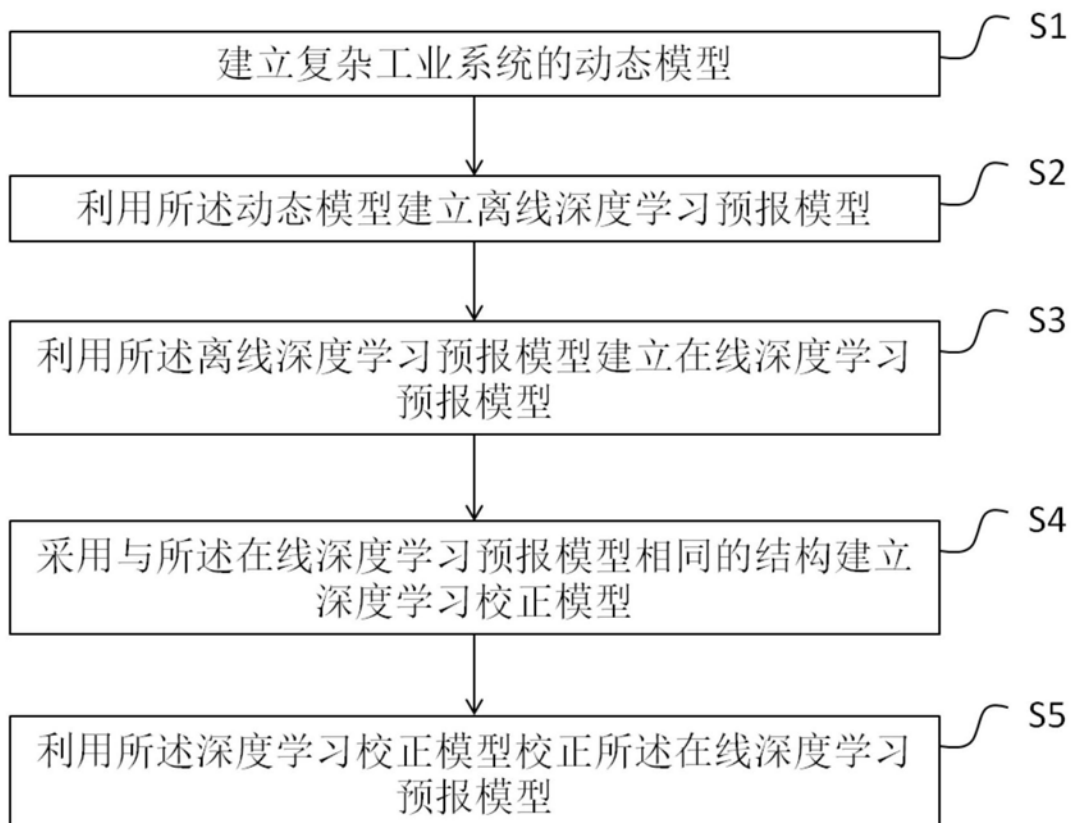


图1

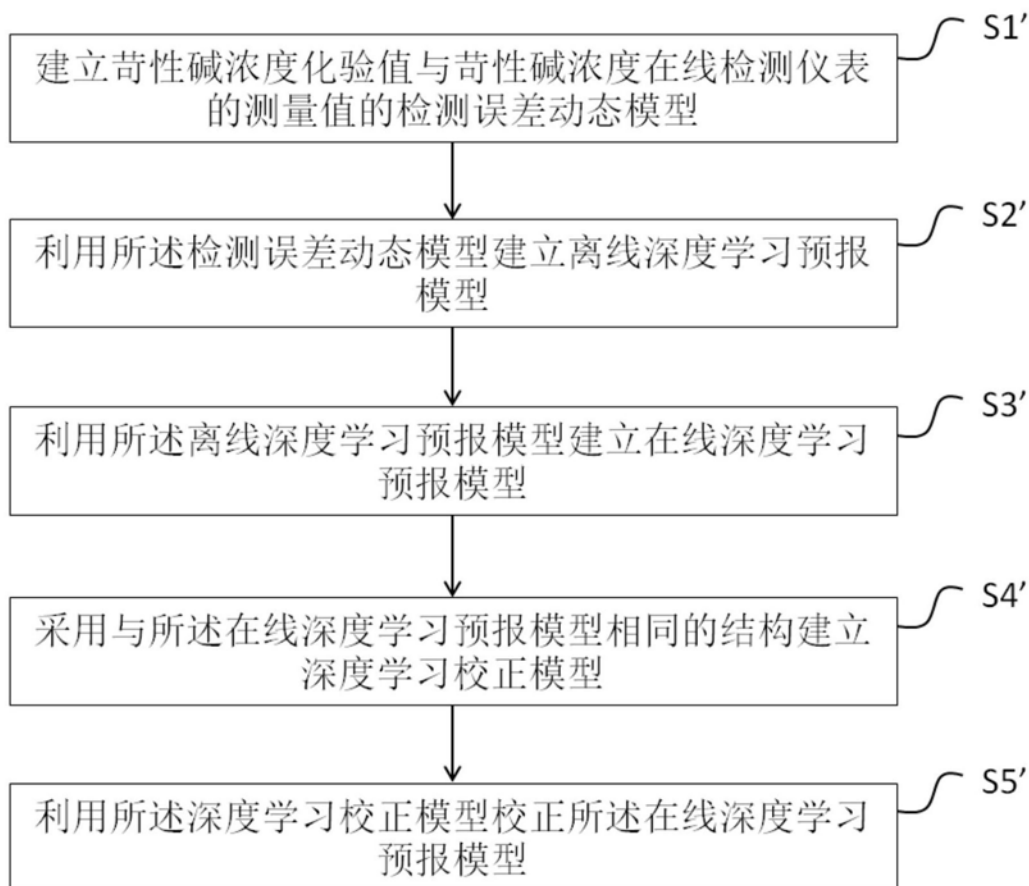


图2




图3

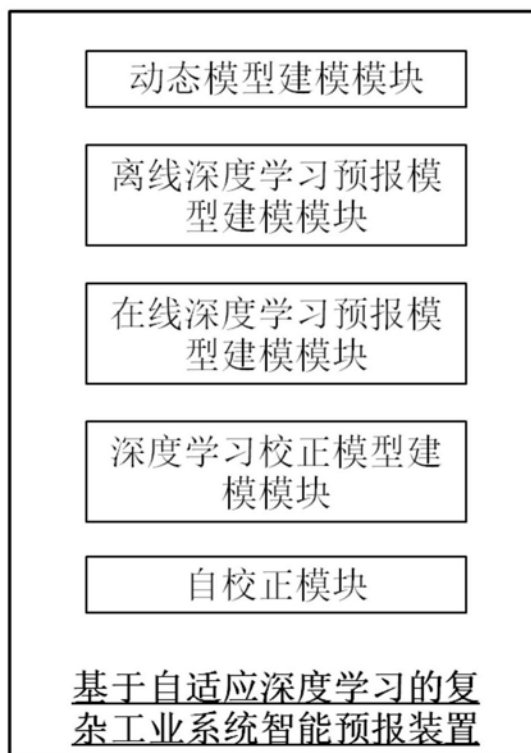


图4

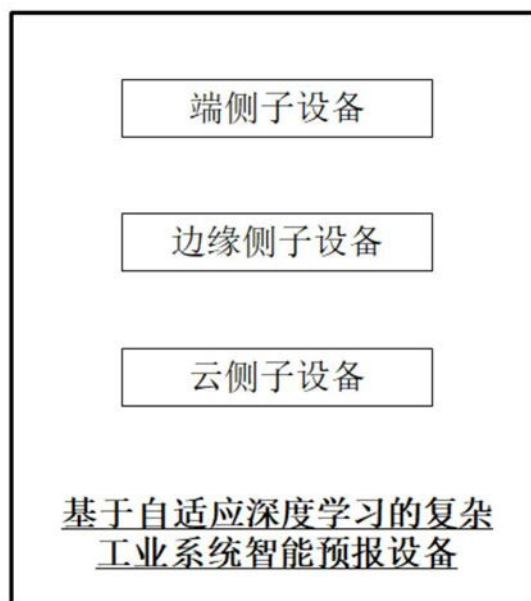


图5